

계측은 정상인데 , 방은 춥다

Plant Reliability Agent

설비 이상 신고가 들어오면 , 첫 조사는 AI 에이전트가 먼저

Built with **NVIDIA Nemotron 3 Ultra**

GitHub github.com/juyoungml/nvidia-hackathon

Live demo juyoung.site/nvidia-hackathon

Team Sona · NVIDIA Korea Agentic AI Hackathon

문제

발전소가 멈추면 , 비용이 크다

연 1.4 조 달러

포춘 글로벌 500 기업이 비계획 정지로 잃는
비용

매출의 약 11%


2019-2020 년 약 8% 에서 증가

이상을 빨리 알아채고 , 원인을 빨리 찾아야 한다

출처 : Siemens, The True Cost of Downtime 2024 · 대형 산업 전반 수치 (발전소 한정 아님)

판단이 어려운 이유


왜 어려운가 : 자료가 흩어져 있다



계측이 정상처럼 보이면 **더 어렵다**

제약

보안 때문에 클라우드 AI 는 어렵다



평가 모델 **Nemotron 3 Ultra** · 전체 550B / 동작 55B (MoE)

Nemotron 3 Ultra 550B · 평가 모델

DGX Spark 약 4 대

약 330-358GB(NVFP4 + 여유) · 최소 3 대, 권장 4 대 · 추정

Nemotron 3 Super 120B · 가벼운 대안 (미평가)

DGX Spark 1 대

약 72-78GB · Spark 1 대 메모리 128GB

DGX Spark 128GB 통합 메모리 (NVIDIA 공식) · 대수는 저희 계산 · 예: 북미 NERC CIP-005 전자 보안 경계 · 국내 국가 망 보안체계 (N2SF)

해법 : 빠른 감시 + 깊은 조사

System 1 · 상시 감시

항상 켜짐
트렌드 감시 · 알람
가볍고 빠르게

Nemotron Nano (후보)

설계 · 이전 실험

System 2 · 원인 조사

문제 발생 시 실행
도면 · TM·WO· 트렌드 연결
원인 · 다음 점검 제안

Nemotron 3 Ultra


구현 · 오늘 데모

왜 나누나 상시 감시는 빠르게 , 원인 조사는 깊게

전체 구조

Plant Reliability Agent · 전체 구조

 NVIDIA 기술  구현·데모  설계·계획 (점선)



현재 데모: 공개 PreDist v2 지역난방 데이터 (계측·신고·정비 기록). 도면 연결·System 1은 설계 단계.

System 1 이 감당할 양

50,000

신호

100 ms

갱신 주기

50 만 / 초

관측값

691 GB/ 일

값 + 시각 16 바이트 기준

시계열 코드

요약 · 후보 추출



Nano

사건 묶기 · 우선순위



Ultra


선별된 사건만 조사

원시 데이터를 전부 큰 모델에 보내지 않는다

현재 로컬 Nano 요청 6.3~11.5 초 → 병목 가능, 부하 시험이 다음 과제

고객 데이터는 비공개 → 공개 데이터로 벤치마크 구성

데이터 : 공개 PreDist v2 (지역난방)



샤워기 물이 뜨거워도 , 수압이 약하면 씻기 어렵다

실제 신고 : " 난방이 안 된다 "


신고 직전 마지막 계측 (14:10)

63.9°C 공급

63.8°C 목표

→ 정상처럼 보인다

하지만 그전 24 시간에는
최대 13.4°C 벌어졌다



■ 실제 공급온도 ■ 목표 온도

17 번 서브스테이션 · 2019-01-09 14:18 신고 · 24 시간 , 10 분 간격 144 개 기록

사례 29

에이전트가 한 일

Nemotron 3 Ultra 가 고른 자료 6 종

최근 계측

센서 설명

과거 신고

정비 기록

목표 이탈 시간대

13:00~14:18 재조회



점검 3 가지 · 원본 기록에 연결

① 실내 · 라디에이터 온도 확인

② 건물 배관 유량 측정

③ 제어기 설정 · 경보 기록 검토

+ 데이터로 알 수 없는 것도 함께 전달

약 20 초

모델 · 도구 실행 시간 (현장 처리 시간 아님)

판단은 엔지니어가 한다

로컬 · 보안 환경용 에이전트를 빠르게


구조와 NVIDIA 기술



실행 환경 생태계가 갖춰져 있어 로컬 · 보안 환경용 에이전트를 빠르게 구성

PreDist 사건 32 건 · 같은 자료 · 같은 출력 형식 · 사건당 1 회

평가 결과 : 판단의 질은 상한선에 가깝다



Sonnet 5 = 클라우드 상한선

보안상 현장 사용 불가 · 32/32

Ultra 가 쓴 점검안 15 개

근거 조작 0 건 · 모두 검사 통과


놓친 17 건의 이유

API 오류 13 · 도구 실수 4 (한 가지)

내용 점수 41 : 42 / 48 (2 건)

격차는 판단력이 아니라 실행 안정성 → 현장 배포 + 도구 보완으로 오프라인에서 해결 예정

다음 단계



판단은 엔지니어가 , 자료 수집은 Plant 가 .

GitHub github.com/juyoungml/nvidia-hackathon · Live demo juyoung.site/nvidia-hackathon · 데모는 저장된 실제 실행 기록을 재생합니다