

Plant Reliability Agent

기술 설계 및 검증 보고서 / NVIDIA Korea Agentic AI Hackathon 2026 / 2026-09-28

01 문제 정의와 검증 범위

공개 에너지 설비 사건을 이용한 이단계 조사 에이전트의 설계 및 검증

요약

Plant Reliability Agent는 설비 이상을 조사하는 엔지니어에게 관측 사실, 관련 기록, 미확인 항목과 다음 점검을 제시하는 프로토타입이다. 작은 모델의 사건 선별(System 1)과 큰 모델의 도구 기반 조사(System 2)를 연결했다. 공개 지역난방 설비의 실제 신고 3건과 파생 시험 2건을 실행했으며, 근거 조치는 작동했지만 선별 오류와 출처 누락이 관측됐다. 현재 자료로 모델 우월성이나 현장 식별 시간 단축을 결론낼 수는 없다. [E1]

현장에서 해결하려는 작업

알람 발생 후의 조사는 한 신호의 임계값 확인으로 끝나지 않는다. 공급 계통, 사용처, 회수 경로가 연결되어 있으므로 센서가 측정된 위치와 사용자가 문제를 경험한 위치가 다를 수 있다. DOE의 증기 계통 설명도 생성·분배·사용·회수를 구분한다. [1] 본 프로젝트는 이 관계를 확인하기 위해 도면, 계획, 과거 기록을 찾아 대조하는 작업을 지원한다. 운영자의 실제 업무 시간이나 설비 규모는 이번 공개 실험에서 측정하지 않았다.

사용자에게 전달할 결과

결과물의 단위는 유창한 진단 문장이 아니라 검토 가능한 조사 자료다. 사건 시점과 설비, 관측값의 출처, 그 근거로 판단할 수 없는 것, 다음에 확보할 측정·기록을 함께 제시한다. 원인 확정과 설비 조치는 사람의 판단으로 남긴다. 출처가 존재하는지와 해당 출처가 실제로 문장을 뒷받침하는지는 별도 검증해야 한다.

적용 대상과 현재 증거의 차이

발전소 운전·정비 조사를 목표로 하지만, 현재 실행 데이터는 동일한 지역난방 서브스테이션의 3개 신고다. DOE 계통도는 별도의 공개 문서 탐색 예시이며 이 신고들의 설비 도면이 아니다. 수만 개 센서의 상시 감시, 자동 P&ID 인덱싱, 고객 데이터 적용은 구현 또는 검증 범위에 포함되지 않는다.

항목	확인된 범위	확인되지 않은 범위
에이전트	Nano 선별과 Ultra 도구 조사 실행	실시간 연속 감시·현장 진단 정확도
자료	실제 신고 3건 + 파생 시험 2건	독립 설비·다양한 고장 유형 일반화
가치	근거와 다음 점검의 출력	식별 시간·발전량·금전 효과

검증 기준일: 2026-09-28. [E1] evaluation/results/comparison.json 및 traces/. 팀명 미정 · 임시 서비스명 사용.

02 설계 선택과 반증 가능한 가설

모델을 두 개 사용하는 이유는 비용과 판단의 역할을 분리하기 위해서다. 이점은 별도로 입증해야 한다.

H1. 선별과 조사의 역할 분리

상시 입력마다 큰 모델이 모든 자료를 조사하면 호출량과 지연이 증가할 수 있다. System 1은 신고 범주와 공급온도-설정값의 집계 특징만 받아 조사 여부를 반환하고, System 2는 선택된 사건에 한해 상세 근거를 읽는다. 현재 실험은 저장 구간 재생이며 연속 스트리밍이 아니다. 파이프라인 비용은 $C_{\text{Nano}} + p \times C_{\text{Ultra}}$ 로 생각할 수 있으나, 전체 Ultra 호출 방식보다 유리하려면 선별 비용과 추가 오류를 포함해 비교해야 한다. 비용 단가·호출 절감 효과는 아직 측정하지 않았다.

H2. 사전 연결된 근거가 탐색 부담을 줄인다

문서의 페이지·영역, 설비 별칭, 센서 태그와 개정본을 미리 연결하면 사건 발생 후 조회 범위를 좁힐 수 있다. NeMo Retriever의 문서 추출·임베딩·재정렬을 이 계층의 후보로 검토했다. [3] 다만 문서 요소 추출이 P&ID 배관 관계의 정확한 해석을 보장하지는 않는다. 현재 도면은 수동 영역 지정이며, 검색 지연·검색 재현율·태그 연결 정확도 개선은 미검증이다.

H3. 출처와 보류 사유가 검토 가능성을 높인다

모델이 즉시 원인을 단정하는 대신 관측 사실과 필요한 추가 정보를 분리하도록 도구 설명과 출력 지침을 작성했다. 그러나 지침만으로 출처 누락을 막지는 못했다. 다음 구현에서는 최종 답변을 구조화된 주장·근거 쌍으로 만들고, 각 주장에 대한 출처 연결을 출력 조건으로 검증해야 한다.

왜 NVIDIA 구성인가

Nemotron은 서로 다른 크기의 모델로 선별과 조사를 실험하는 실행 기반이다. NAT는 도메인 도구 등록과 워크플로 재현에 사용했고, OpenShell은 별도 최소 환경에서 정책 적용을 확인했다. NVIDIA 제품명을 나열하는 것이 기여가 아니라, 각 구성요소의 실행 기록과 한계를 함께 제시하는 것이 이번 검증의 기준이다. [4][5]


비교 대상	현재 비교	다음 통과 기준
Nano vs 규칙	3개 신고에서 모두 같은 조사 결정	무신고·정상·모호한 사건에서 오류와 비용 비교
Ultra vs 고정 요약	동일 replay 기반 출력 비교	주장별 근거 타당성과 점검 유용성의 독립 평가
연결 인덱스 vs 문서 탐색	아직 미실행	동일 질문에서 검색 시간과 근거 재현율 측정

H1-H3은 설계 가설이다. 이번 자료만으로 두 모델 구조 또는 인덱싱의 우월성을 주장하지 않는다.

03 System design: 실행 경로와 데이터 경계

실선은 실행된 모델·도구 경로, 점선은 제안 단계인 문서 인덱싱 경로를 나타낸다.

FIGURE 01 / SYSTEM PATH



System 1 입력·출력 계약

입력은 사건 시점, 신고 범주, 계측 수, 마지막 계측 시점과 공급온도-설정값 편차 집계다. 로컬 Ollama의 nemotron-3-nano:4b는 escalate, priority, reason, evidence_kinds를 반환한다. 검증기는 필드·자료형·열거값·우선순위 일관성을 검사한다. 긴 출처 ID는 모델이 복사하지 않고, 선택된 근거 종류를 런타임이 원본 ID로 연결한다. [E2]

보수적 전달 규칙과 의미 검증의 한계

출력 형식이 잘못되면 검토 대상으로 넘긴다. 서비스 중단 신고에 규칙이 반응하면 모델의 보류 판단을 상향한다. 이는 신고 누락 방지를 위한 정책이며 모델 성능으로 계산하지 않는다. 형식이 유효해도 이유가 사실과 다를 수 있다는 점은 무신고 시험에서 드러났다. 현재 검증기는 이러한 의미 오류를 완전히 차단하지 않는다.

System 2 도구 실행

공개 replay만을 대상으로 계측, 이전 신고, 정비 타임라인, 신호 정의의 네 읽기 도구를 제공한다. hosted nvidia/nemotron-3-ultra-550b-a55b는 실제 사건마다 앞의 두 도구를 호출했다. 도구 라운드는 6회로 제한하고, 미정의 태그·일부 단정 표현에 대해서만 수정 요청과 보류 장치를 둔다. 출처 문장 누락 전체를 보장하는 검증은 아니다.

배포 경계

이번 hosted API에는 공개 자료만 전달했다. 회사 데이터의 현장 배포는 추출·인덱스·모델 추론을 사내 경계에 두는 별도 설계다. OpenShell 최소 정책 시험과 현재 모델 파이프라인은 아직 통합되지 않았다.

[E2] poc/run.py, poc/trace-52-pipeline.json. 모델 루프는 Python 구현이다. NAT의 별도 도구 재생산을 전체 루프 통합으로 표시하지 않는다.

04 데이터 구성과 사건 재생 방법

동일 설비의 3개 공개 신고를 대상으로, 현재 사건의 사후 진단을 숨긴 채 조사 과정을 재생했다.

FIGURE 02 / INCIDENT RESPONSE



근거가 부족하면 결론을 보류하고 추가 확인을 요청

데이터 선정

PreDist v2는 지역난방 설비의 계측과 장애·정비 정보를 함께 제공한다. [2] 본 실험은 원자료의 M1 서브스테이션 21에서 신고 52·62·32를 선택했다. 각 신고 직전 24시간의 144개 계측과 그보다 이른 기록을 포함한다. 평균 공급 온도-설정값 절대 편차는 각각 0.31, 0.33, 0.35°C였고 모두 144개 중 144개가 2°C 이내였다. 이 세 사건은 독립적인 고장 유형의 대표 표본이 아니다.

시간 경계와 데이터 누출 통제

현재 신고에서는 문제 범주만 사용한다. 현재 사건의 사후 원인·조치는 evaluation/held-out-*.json에 두고 실행 루프가 읽지 않는다. 계측은 신고 시각 이하, 이전 기록은 신고 시각 미만으로 검사한다. 다만 이전 보고서의 회고적 서술이 운영자에게 알려진 시점은 원자료에서 확인되지 않으므로 완전한 실시간 정보 재현으로 해석할 수 없다.

기준선과 파생 시험

같은 replay를 읽는 고정 요약 템플릿과 신고 키워드 규칙을 기준선으로 둔다. 이 템플릿은 사람 또는 최적 LLM의 성능을 대신하지 않는다. 실제 계측 구간에서 신고를 제공하지 않는 시험과, 사례 52의 계측을 제거한 시험을 따로 만들었다. 두 시험은 실제 신고 건수에 합산하지 않으며 무신고 구간을 정상 운전 정답으로 간주하지 않는다.

실제 신고	신고 시각	샘플 / 이전 신고	편차 평균
52	2016-12-12 15:55	144 / 1	0.31°C
62	2019-01-21 08:17	144 / 2	0.33°C
32	2019-10-19 10:38	144 / 3	0.35°C

원자료 CSV 해시는 각 replay.provenance에 저장했다. 계측 편차는 관측 통계이며 고객 실내의 난방 상태를 뜻하지 않는다.

05 관측 결과와 실패 분석

도구 기반 조사는 실행됐지만, 선별의 추가 가치와 완전한 출처 연결은 아직 입증되지 않았다.

실제 사건의 실행 결과

세 신고 모두 Nano와 규칙 기준선이 조사 필요로 분류했다. Ultra는 각 사건에서 계측과 이전 신고 도구를 두 번 호출했다. 네 조사 답변(실제 3건과 계측 제거 1건)에 미정의 신호 태그나 잘못된 완전형 출처 ID는 발견되지 않았다. 그러나 출처의 존재 여부만 검사하면, 중요한 사실에 출처가 아예 없는 문제를 놓친다.

출처 누락

사례 52는 계측값을 설명하면서 계측 출처 ID를 명시하지 않았고, 현재 신고 ID도 빠뜨렸다. 사례 32는 현재 신고 ID를 생략했다. 사례 62만 두 ID를 모두 포함했다. 따라서 '잘못된 출처 0개'를 '모든 주장에 근거가 있다'로 해석하지 않는다. 원문 답변을 보존하고 주장별 근거 검토를 후속 평가로 남긴다. [E1]

Nano의 무신고 시험 실패

신고가 없다는 입력에서 Nano는 서비스 중단 신고가 있다는 이유를 만들어 조사를 요청했다. 규칙은 조사하지 않는 것으로 판단했다. 이 시험은 gate만 실행해 Ultra는 호출하지 않았다. 검증된 정상 상태가 아니므로 현장 오염물로 환산할 수는 없지만, 제공되지 않은 신고를 이유로 쓴 명확한 오류다.

해석

계측 제거 시험에서는 표본이 없음을 밝히고 원인 결론을 보류했다. 이는 결측 처리의 제한적 증거다. 각 시험은 단일 실행이며 반복 변동·운영자 비교·정답 진단·비용 절감은 측정하지 않았다. 아래 시간은 모델 요청 합계이고 현장 식별 시간이 아니다.

시험	Nano / 규칙	Ultra 도구	신고/계측 인용	Nano / Ultra 초
52 실제	조사 / 조사	2	누락 / 누락	6.70 / 22.90
62 실제	조사 / 조사	2	있음 / 있음	11.50 / 17.29
32 실제	조사 / 조사	2	누락 / 있음	6.26 / 18.63
무신고 파생	조사 / 보류	0	해당 없음	10.09 / 0
계측 제거 파생	조사 / 조사	2	있음 / 계측 없음	3.54 / 12.32

[E1] evaluation/results/README.md, comparison.json, traces/. 자동 검사와 사람이 해석한 실패를 구분했다. 최고 실행을 고른 평균이 아니라 보존된 단일 실행 기록이다.

06 도구 통합과 보안 경계 시험

NAT의 실행 증거와 OpenShell의 정책 증거는 각각 확보했으며, 모델 파이프라인 전체의 보호와 구분한다.

FIGURE 03 / SECURITY SCOPE

격리된 OpenShell 프로브

명령 → 정책 검사
허용 파일 읽기 → exit 0
금지 읽기/쓰기/TCP → exit 1

운영 경계 (제안)

로컬 S1 · 현장 데이터 배치
권한 정책 · 운영 통신 경로
실제 배포 환경에서 재검증 필요

프로브에는 호스트 마운트와 모델 엔드포인트가 없음

NeMo Agent Toolkit 1.8.0

공개 읽기 도구 네 개를 FunctionGroup으로 등록하고, 저장된 Ultra trace에 나타난 세 도구를 고정 순서로 실행했다. 이 재생은 NAT에서 도메인 도구를 실행할 수 있음을 확인한 것이다. 새로운 모델 호출이나 전체 Nano-Ultra 루프의 NAT 실행은 아니다. 결과에는 버전, 호출 이름, 출처 ID와 결과 해시를 남겼다. [E3]

OpenShell 0.1.2 최소 정책 시험

macOS arm64와 Docker Desktop에서 임시 인증 gateway 및 sandbox를 만들고, 공개 문자열 두 개만 들어 있는 이미지를 실행했다. /work/allowed만 읽도록 허용하고 /work/denied, 쓰기와 직접 TCP 연결을 차단했다. 호스트 workspace·home·API 키·회사 자료는 연결하지 않았다. 시험 후 sandbox, gateway와 임시 자원을 정리했다. [E4]

무엇을 입증했고 무엇이 남았나

아래 결과는 특정 이미지와 로드된 정책에 대한 실행 증거다. prompt injection 저항성, 모델 endpoint 통신, 전체 도구 체인의 정책 준수 또는 고객 데이터 보호의 실증은 아니다. 운영 적용 전에는 필요한 통신만 허용한 상태에서 실제 조사 루프를 통합하고 정책 우회·예외·감사 로그를 검증해야 한다.


프로브	예상 정책	관측 결과
허용 파일 읽기	허용	exit 0 / 원문 확인
비허용 파일 읽기	차단	exit 1 / Permission denied
허용 경로에 쓰기	차단	exit 1 / Permission denied
직접 TCP 1.1.1.1:443	차단	exit 1 / Permission denied

[E3] integrations/trace.json. [E4] integrations/openshell-trace.json 및 openshell-policy.yaml. 정책 revision Loaded, 해시 7a423439...98e04.

07 식별 시간과 경제적 가치의 연결

모델 응답이 빠르다는 것과 설비 복구가 빨라지는 것은 다른 주장이다.

FIGURE 04 / ILLUSTRATIVE TIME MODEL



식별 8→0.5 h · 준비 4 h · 수리 8 h

차이 7.5 h는 관측 성과가 아닌 시나리오 계산

경제성 가정의 위치

Plant Economics Bench의 설명 시나리오는 식별 8시간, 준비 4시간, 수리 8시간을 기준으로 둔다. 식별만 0.5시간으로 바꾸면 총 소요 시간이 20시간에서 12.5시간으로 줄어드는 산술적 결과를 얻는다. 이 7.5시간은 실제 절감 관측치가 아니다. 준비·수리·운전 제약이 그대로이고 식별 단축이 복구 시작에 온전히 반영된다는 가정이 필요하다.

측정할 양

현장 식별 시간은 사건 인지부터 올바른 원인 또는 사전에 정한 충분한 점검 결정에 도달할 때까지로 정의해야 한다. 두 종료 기준은 서로 바꾸어 쓰면 안 된다. 회수 발전량은 단축된 시간 구간에서 실제 회복 가능한 출력의 적분이고, 가치는 급전·판매 가능 조건과 변동비를 반영해야 한다. 이번 실험에서는 어느 값도 직접 측정하지 않았다.

다음 실험의 통과 기준

우선 동일한 공개 입력과 동일한 종료 기준으로 규칙, 고정 요약, Ultra 단독, Nano-Ultra를 비교한다. 단순 시간 평균 외에 잘못된 결론, 미탐, 불필요한 조사, 출처 누락을 함께 기록한다. 이후 도메인 검토자가 원인 또는 점검안의 타당성을 독립적으로 판정하고, 현장 확인 시간까지 포함한 평가로 확대한다.

다음 구현의 우선순위

출처 누락을 막는 주장-근거 구조와 무신고 입력의 의미 검증을 먼저 보완한다. 자동 도면 인덱싱은 별도 검색 평가로 검증하고, NAT와 OpenShell 통합은 정상 실행과 허용되지 않은 요청을 함께 시험한다. 시각적 완성도보다 이 네 가지 검증이 현장 적용의 판단 근거가 된다.

이 페이지의 시간은 가정·목표다. 운영자 대비 절감, 회수 MWh, 연간 금액 또는 사업 성과로 제출하지 않는다.

08 재현 절차와 근거 목록

보고서의 수치와 주장은 저장된 공개 자료·실행 기록으로 추적할 수 있도록 구성했다.

결과 열람과 재실행

저장소 루트에서 `python3 scripts/serve_demo.py --port 8772`를 실행하고 `/web/investigation.html`을 연다. 화면은 저장된 실제 trace를 재생하며 API 키가 필요 없다. 새 실행은 README의 `uv` 명령, 로컬 Ollama Nano와 본인 NVIDIA 키가 필요하다. 키는 제출물에서 제외한다. 임시 서비스명으로 작성했으며 팀명과 팀원별 신청은 별도 확정해야 한다.

공식 자료

- [1] U.S. DOE, Improving Steam System Performance, 2nd ed., Figure 1 / 본문 p.3.
<https://www.energy.gov/sites/prod/files/2014/05/f15/steamsourcebook.pdf>
- [2] Roelofs et al., PreDist dataset v2. DOI 10.5281/zenodo.19496480.
<https://zenodo.org/records/19496480>
- [3] NVIDIA NeMo Retriever Library Overview. <https://docs.nvidia.com/nemo/retriever/latest/extraction/overview/>
- [4] NVIDIA NeMo Agent Toolkit 1.8 Overview. <https://docs.nvidia.com/nemo/agent-toolkit/latest/index.html>
- [5] NVIDIA OpenShell Policy Schema. <https://docs.nvidia.com/openshell/latest/how-it-works/policies/schema>

프로젝트 증거

- [E1] `evaluation/results/comparison.json`, `README.md` 및 `traces/`: 사건별 원문 답변·선별·구조 검사·지연.
- [E2] `poc/run.py`, `trace-52-pipeline.json`, `runtime-probe-log.json`: 실행 계약과 공급자·출력 실패.
- [E3] `integrations/nat_replay.py`, `trace.json`, `requirements.lock`: NAT 등록·실행과 버전.
- [E4] `integrations/openshell-trace.json`, `openshell-policy.yaml`, `openshell-README.md`: 정책과 허용/차단 결과.

보고서의 최종 판단

공개 기록에 대한 선별·조사 파이프라인과 제한된 도구·정책 실행은 재현했다. 현재 가장 중요한 미해결 문제는 Nano 선별의 사실성, Ultra 인용의 완전성, 현장 식별 기준의 부재다. 이 세 항목을 통과하기 전에는 운영 성능이나 경제 효과가 입증됐다고 주장하지 않는다.

문서 기준: 2026-09-28. 공개 자료 외의 고객·회사 기록은 포함하지 않는다. source provenance는 `data/README.md` 및 `web/assets/SOURCES.md` 참조.